

**CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA DE MINAS GERAIS
CAMPUS TIMÓTEO**

Marcos Vinícius de Oliveira Silva

**COMPARAÇÃO ENTRE MODELOS DE TRADUÇÃO NEURAI
BASEADOS NA ARQUITETURA TRANSFORMER DE CÓDIGO
ABERTO**

Timóteo

2026

Marcos Vinícius de Oliveira Silva

**COMPARAÇÃO ENTRE MODELOS DE TRADUÇÃO NEURAIS
BASEADOS NA ARQUITETURA TRANSFORMER DE CÓDIGO
ABERTO**

Monografia apresentada à Coordenação de Engenharia de Computação do Campus Timóteo do Centro Federal de Educação Tecnológica de Minas Gerais para obtenção do grau de Bacharel em Engenharia de Computação.

Orientador: Douglas Nunes de Oliveira

Timóteo

2026

À, Jonas Garcia de Oliveira, colega, amigo e avô

Agradecimentos

Agradeço aos pais no primeiro parágrafo?

E à namorada ou ao namorado no segundo?

Orientador no terceiro?

Esta página de agradecimentos vive dando problemas.

“Por pior que a vida pareça, sempre existe algo que você possa fazer e ser bem-sucedido”.
Stephen Hawking

Resumo

Um único parágrafo que sintetize todo o meu trabalho. Organização de informação usando classificação facetada é útil para melhorar a indexação de documentos e a construção de sistemas de recuperação de informação corporativa. Essa hipótese baseia-se na evidência de facetas comuns a documentos de diferentes empresas e na flexibilidade da organização facetada. Entretanto, a classificação e indexação automáticas de um grande volume de documentos representam importantes obstáculos e nossa principal motivação. A pesquisa é descritiva, aplicada e experimental e tenta responder sobre a existência de características comuns a documentos do domínio corporativo e a possibilidade de indexação facetada automática. Duas coleções são usadas para avaliação, uma pública e outra particular. Os termos usados por autores de documentos foram obtidos através de documentos e expressões de busca. Foi empreendida uma análise preliminar do domínio corporativo, pela qual foram descobertas 12 categorias comuns e facetas úteis para o contexto de cada coleção de avaliação. A distribuição de assuntos em categorias apresentou alta correlação positiva usando o coeficiente de correlação de Spearman. Dez expressões de busca de usuários foram avaliadas no contexto da coleção particular e validaram as 12 categorias comuns. A avaliação empírica da trilha *Enterprise* da *Text Retrieval Conference* foi executada e os métodos de indexação, classificação e recuperação automáticos de informação facetada melhoraram a eficiência da recuperação sem fazer uso de serviços externos, como Wikipedia e metabuscadores, e sem fazer uso de estruturas hipertextuais presentes nos documentos da amostra. A avaliação empírica utilizou-se principalmente das características espaciais, temporais, de documento e de pessoal. A técnica de análise facetada mostrou-se promissora para os métodos de análise e comparação de coleções corporativas sem que dados puros sejam expostos a terceiros. A tese aponta direções de pesquisa para o uso dos métodos em outras coleções, para aperfeiçoamentos da organização da informação facetada, e para novas aplicações dos métodos também em outros domínios.

Palavras-chave: análise de domínio, análise facetada, recuperação de informação, informação corporativa.

Abstract

We hypothesise that information organisation based on faceted classification is useful to improve enterprise information retrieval systems. The existence of similar facets in documents from different companies and the known adaptability of facet organisation strengthen this hypothesis. We refer this work to the automated classification and indexing on large amounts of text files. This work is descriptive, applied, and experimental. It aimed to expose the main characteristics of the enterprise information, proposing a tentative generalisation to the enterprise domain and presenting some facets we can use to organise it and to support better information retrieval. It applied facet analysis to two enterprise collections and evaluated the resulting faceted classification. Terms were selected from documents and queries. We found twelve common categories and the distribution of document subjects across the categories presents strong positive correlation by the Spearman's rank correlation. Then, we obtained ten user queries and we adopted them to validate the found categories. We also used the Enterprise track of Text Retrieval Conference and its previous results as a Cranfield-like evaluation. The automated prototype used spatial, temporal, document and social characteristics. Thus, our empirical evaluation improved the information retrieval with no external dependency like Wikipedia or metasearch engines. The facet analysis was useful for comparing the companies with no desire to expose their information. The method can guide and stimulate future work and other companies can become more willing to take part in a research study.

Keywords: domain analysis, facet analysis, information retrieval, enterprise information.

Lista de ilustrações

Figura 1 – Tradução Automática Baseada em Regras	15
Figura 2 – Tradução Automática Baseada em estatística	17
Figura 3 – Tradução automática neural	18

Lista de tabelas

Lista de abreviaturas e siglas

RNN	Redes neurais recorrentes
CPU	Unidade central de processamento
RAM	Memória de acesso aleatório
BLEU	Substituto para avaliação bilíngue
SMT	Tradução Automática Estatística
RBMT	Tradução Automática Baseada em Regras
NMT	tradução automática neural

Sumário

1	INTRODUÇÃO	11
1.1	Justificativa	11
1.2	Problema	12
1.3	Objetivos	12
2	EVOLUÇÃO DA TRADUÇÃO AUTOMÁTICA	14
2.1	Tradução Automática Baseada em Regras	14
2.2	Tradução Automática Estatística	16
2.3	Tradução automática neural	18
3	REFERENCIAL TEÓRICO	21
3.1	Tradução automática neural - NMT	21
3.2	Tokenização	21
3.3	Embedding	21
3.4	Modelo Sequence-to-Sequence	21
3.5	Função softmax	21
3.6	Mecanismo de Atenção	21
3.7	Arquitetura Transformer	21
3.7.1	Visão Geral	21
3.7.2	Codificador	21
3.7.3	Decodificador	21
3.7.4	Feed-Forward	21
3.7.5	multi-head attention	21
3.7.6	positional encoding	21
3.7.7	paralelização	21
3.8	Modelos de Tradução Open Source	21
3.8.1	MarianMT	21
3.8.2	M2M	21
3.8.3	NLLB	21
3.9	Métricas de Avaliação	21
3.9.1	BLEU	21
3.9.2	BERTScore	21
3.9.3	chrF	21
3.10	Eficiência Computacional	21
	REFERÊNCIAS	22

1 Introdução

O mundo passou e continua passando por grandes mudanças tecnológicas nos últimos anos, o que possibilitou a presença da tecnologia em diversos setores econômicos (CLARO, 2009). Juntamente com essa presença tecnológica, as pessoas passaram a se tornar mais ativas no ambiente virtual, uma vez que a tecnologia faz parte do dia a dia. Em conjunto com essa presença digital, tornou-se notável o aumento do consumo de conteúdos em outros idiomas, bem como a realização de compras de produtos, sejam eles físicos ou digitais, também em línguas estrangeiras (BULLA, 2024).

Ferramentas de tradução são muito úteis para pessoas que não são capazes de compreender a língua que está sendo apresentada. Uma alternativa para contornar o problema da barreira linguística é a utilização de tradutores automáticos, capazes de identificar o conteúdo transmitido por meio do contexto e da forma de escrita, gerando uma tradução que se assemelhe ao máximo à língua de destino. Atualmente, existem diferentes ferramentas que realizam a tradução de uma língua de origem para uma língua de destino. Como exemplo, podem ser citadas as ferramentas Google Tradutor, DeepL, Smartling e Lokalise, todas com o mesmo objetivo: traduzir textos mantendo o contexto e o sentido da sentença original.

Até o ano de 2017, diferentes técnicas e algoritmos foram utilizados para a tradução entre línguas. Dentre as abordagens existentes, destacam-se inicialmente as técnicas baseadas em regras gramaticais (Rule-Based Machine Translation - RBMT), que representaram uma das primeiras fases das ferramentas de tradução (TORREGROSA et al., 2019). Posteriormente, surgiram os modelos baseados em métodos estatísticos (Statistical Machine Translation – SMT), que representaram um avanço significativo na tarefa de tradução, alcançando níveis mais satisfatórios e adaptativos em comparação às abordagens baseadas em regras gramaticais (LOPEZ, 2008).

Ainda antes de 2017, modelos baseados em redes neurais recorrentes (RNN) passaram a ser amplamente utilizados na tarefa de tradução, sendo bem aceitos por apresentarem resultados superiores em relação às abordagens anteriores (DANG, 2023). No entanto, em 2017, foi proposta a arquitetura Transformer, que trouxe modificações relevantes em relação aos modelos anteriores, como o uso do mecanismo de autoatenção. Esse mecanismo possibilitou avanços significativos na identificação de contexto e na análise de sequências mais longas, contribuindo para traduções mais precisas, tanto em termos de contexto quanto na captura de dependências em textos mais extensos (ANAND et al., 2025).

1.1 Justificativa

Atualmente, existem diversos modelos de tradução baseados na arquitetura Transformer e disponibilizados como código aberto. Empresas como Meta e Google, além de iniciativas como o MarianMT, que não possui fins lucrativos, estão em constante desenvolvimento e pes-

quisa na área de tradução entre línguas (FEINER; LESWING, 2025). Esse cenário evidencia que a área de tradução automática encontra-se em constante evolução, podendo trazer benefícios em escala global, especialmente para a população brasileira, na qual apenas uma parcela possui fluência na língua inglesa (OLIVEIRA, 2026). Dessa forma, avanços em modelos de tradução podem ser amplamente aproveitados por pessoas que desejam ou necessitam consumir, comprar ou até mesmo comercializar produtos e conteúdos em outros idiomas, especialmente em inglês.

Apesar da ampla disponibilidade de modelos de tradução baseados na arquitetura Transformer, sejam eles desenvolvidos por organizações com ou sem fins lucrativos, existem diferenças relevantes entre esses modelos. Tais diferenças podem estar relacionadas à forma como a arquitetura é implementada, bem como às bases de dados utilizadas durante o treinamento. Como consequência, essas variações podem impactar diretamente o comportamento dos modelos em diferentes cenários, influenciando aspectos como consumo de memória, uso de CPU e tempo de resposta, mesmo quando submetidos à mesma entrada.

Diante desse contexto, este trabalho propõe a comparação entre diferentes modelos de tradução automática, com o objetivo de analisar seus desempenhos e apresentar resultados que auxiliem na escolha do modelo mais adequado para diferentes cenários de uso, considerando a tradução entre uma língua de origem e uma língua de destino.

1.2 Problema

A seguinte questão constitui o problema desta pesquisa: Qual é o desempenho de diferentes modelos de tradução entre línguas e automática, baseados na arquitetura Transformer para a tarefa de tradução do inglês para o português, considerando métricas como consumo de memória RAM, uso de CPU, pontuação BLEU, BERTScore e chrF, em diferentes cenários de teste?

1.3 Objetivos

Para responder ao problema proposto, o objetivo geral deste trabalho é investigar e comparar o desempenho de modelos de tradução entre línguas e automática baseados na arquitetura Transformer na tarefa de tradução do inglês para o português, considerando métricas de qualidade (BLEU, BERTScore e chrF) e eficiência computacional (uso de memória RAM e CPU) em diferentes cenários experimentais.

Também, objetivam-se mais especificamente:

1. Revisão bibliográfica sobre o funcionamento de modelos de tradução automática neural baseados na arquitetura Transformer;
2. Selecionar e configurar os modelos de tradução automática neural de código aberto;
3. Selecionar base de dados pública para comparação entre os modelos de tradução automática neural;

4. Avaliar qualidade de tradução utilizando mettricas como BLEU, BERTScore e chrF;
5. Medir eficiência de recursos computacionais quando se utiliza modelos de tradução;
6. Avaliar os modelos de tradução diferentes cenários de teste;
7. Analisar correlação entre métricas de qualidade de tradução.

2 Evolução da Tradução Automática

A área de tradução automática tem passado por transformações significativas ao longo dos anos, seja pela evolução de modelos específicos por meio de técnicas de otimização, seja pela proposição de novas arquiteturas que estabeleceram novos estados da arte. Este capítulo tem como objetivo apresentar um panorama da evolução das técnicas e modelos de tradução automática, desde as abordagens iniciais até os métodos mais recentes, discutindo suas principais características, vantagens e limitações.


2.1 Tradução Automática Baseada em Regras

A tradução automática baseada em regras, do inglês Rule-Based Machine Translation (RBMT), consiste em sistemas que operam com base em um conjunto de regras linguísticas previamente definidas para a língua de destino. Esses sistemas utilizam regras gramaticais para realizar a tradução entre línguas, exigindo um esforço humano significativo na elaboração de todos os componentes necessários para a tradução de uma língua de origem para uma língua de destino.

Entre esses componentes, destacam-se analisadores morfológicos, etiquetadores de classes gramaticais, analisadores sintáticos, dicionários bilíngues, regras de transferência, geradores morfológicos e regras de reordenação, entre outros (S, 2017).

A Figura 1 ilustra o processo de tradução baseado em regras. Nela, uma frase em inglês é fornecida para o sistema, e baseado nas regras pre-definidas da língua portuguesa como língua de destino a tradução é gerada.

Figura 1 – Tradução Automática Baseada em Regras



Fonte: (CHAROENPORNSAWAT; SORNLERLAMVANICH; CHAROENPORN, 2002) adaptada para português

A tradução automática baseada em regras teve início na década de 1970, sendo considerada um marco na área de tradução automática e uma abordagem inicialmente promissora (WIKIPEDIA, 2026). No entanto, algumas características limitaram sua adoção em larga escala (OKPOR, 2014):

- Escassez de dicionários bilíngues de alta qualidade, sendo sua construção uma tarefa custosa;
- Necessidade de configuração manual de diversas informações linguísticas;
- Dificuldade em lidar com ambiguidade linguística e expressões idiomáticas, especialmente em sistemas de grande escala.

Devido a essas limitações, tornou-se necessária a criação de novas abordagens capazes de lidar melhor com ambiguidade, dependências contextuais entre palavras e reduzir a

necessidade de intervenção humana na construção das traduções. Nesse contexto, surgiu a tradução automática baseada em Estatística (Statistical Machine Translation – SMT), que será abordada na próxima seção.

2.2 Tradução Automática Estatística

A abordagem estatística de tradução baseia-se em modelos probabilísticos extraídos de bases textuais bilíngues alinhadas, nos quais cada palavra ou frase da língua de destino é associada a elementos da língua de origem segundo uma determinada probabilidade. Dessa forma, as palavras ou expressões com maior probabilidade, dentre as opções geradas pelo modelo, tendem a corresponder à tradução mais adequada (S, 2017).

Em termos práticos, um modelo de tradução estatística é treinado com grandes volumes de textos paralelos, contendo a língua de origem e sua tradução correspondente na língua de destino. A partir desses dados, o modelo aprende padrões de correspondência entre palavras e frases, sendo capaz de estimar a tradução mais provável com base nas ocorrências observadas durante o treinamento (Lokalise Team, 2025).


O processo de tradução estatística envolve dois módulos principais: o modelo de tradução e o modelo de linguagem (WANG et al., 2017).

O modelo de tradução tem como objetivo mapear como palavras ou frases em uma língua geralmente se correspondem em outra, realizando essa análise no nível de frases, e não apenas de palavras isoladas. Esse cuidado evita traduções que não respeitem o contexto, já que uma mesma palavra na língua de origem pode ter múltiplas traduções possíveis na língua de destino.

O modelo de linguagem, por sua vez, recebe os possíveis mapeamentos gerados pelo modelo de tradução e seleciona a frase que apresenta a maior probabilidade de ocorrência na língua de destino, considerando padrões aprendidos a partir dos textos da base de observação. Esse módulo é essencial para produzir traduções mais naturais, que se aproximem do resultado esperado de uma tradução humana.

A imagem abaixo exemplifica este processo de tradução baseado no modelo estatístico.

Figura 2 – Tradução Automática Baseada em estatística



Fonte: (Lokalise Team, 2025) adaptada para português

É notável que traduções baseadas em estatística superaram traduções baseadas em regras, em qualidade e contexto, porém, os seguintes pontos podem ser destacados sobre traduções estatísticas (WANG et al., 2017):

- Criação de base de dados complexa;
- Resultados inesperados. Fluência superficial pode ser enganosa;
- Tradução baseada em estatística não funciona bem entre línguas que possuem ordem de palavras diferentes;
- Os resultados obtidos tendem a ser mais favoráveis para línguas europeias.
- Dificuldade em lidar com dependências de longa distância em frases.

Para contornar os problemas listados acima, um novo modelo foi proposto, o qual foi a base para construção de modelos utilizados atualmente, conhecido como aprendizado profundo, em inglês, deep learning, que será abordado no próximo capítulo.

2.3 Tradução automática neural

A tradução automática neural, em sua essência, utiliza redes neurais artificiais (Artificial Neural Networks - ANN), cujo objetivo é simular, de forma simplificada, o funcionamento do cérebro humano. Em termos gerais, o sistema recebe uma entrada, neste caso, um texto na língua de origem, e por meio de módulos internos da rede neural, realiza a tradução para a língua de destino (LaraTranslate, 2025).

O processo de tradução é realizado por meio de dois componentes principais: o codificador (encoder) e o decodificador (decoder) (WANG et al., 2022).


O componente de codificação tem como objetivo mapear o texto de entrada em um vetor de valores reais de múltiplas dimensões. Esse vetor representa, de forma abstrata, informações relevantes necessárias para a realização da tradução. A partir dessa representação vetorial, o componente de decodificação utiliza essas informações para gerar o texto correspondente na língua de destino.

De forma geral, o processo de tradução automática neural pode ser descrito pelas seguintes etapas (LaraTranslate, 2025):

- Conversão das palavras em vetores numéricos;
- Processamento desses vetores por meio de uma rede neural com múltiplas camadas;
- Geração de uma distribuição de probabilidade para possíveis traduções;
- Seleção da tradução mais provável.

A Figura 3 ilustra o processo de tradução utilizando redes neurais artificiais, destacando os componentes de codificação e decodificação.

Figura 3 – Tradução automática neural



Fonte: (ELAFFENDI; ALRAJHI, 2022)

O uso da tradução automática neural (Neural Machine Translation – NMT) representou, por muitos anos, uma substituição às técnicas de tradução baseadas em métodos estatísticos. Com a utilização da NMT, tornou-se possível gerar traduções sem a necessidade de intervenção humana direta, baseando-se inteiramente em grandes bases de textos e suas respectivas

traduções, abordagem conhecida como aprendizado fim a fim (end-to-end) (LaraTranslate, 2025).

Essa abordagem possibilitou a geração de traduções com maior captura de contexto e maior naturalidade quando comparadas às traduções estatísticas e baseadas em regras, além de melhorar a modelagem das relações entre palavras em uma sentença, um dos principais desafios enfrentados pelas abordagens anteriores (WANG et al., 2017).

Um marco importante na adoção da tradução automática neural foi a substituição dos modelos estatísticos pelo uso de NMT no Google Tradutor, realizada pela empresa Google em 2016 (SCHUSTER; JOHNSON; THORBY, 2016), evidenciando uma mudança significativa na forma como sistemas de tradução eram desenvolvidos até então.

Apesar dos avanços proporcionados pela tradução automática neural em relação aos métodos anteriores, ainda existem limitações associadas aos modelos baseados em componentes de codificação e decodificação. Dentre essas limitações, destacam-se (LaraTranslate, 2025):

- Dificuldade na paralelização do processamento de sequências de entrada;
- Limitações no tratamento de dependências de longo alcance entre palavras;
- Maior complexidade no processo de treinamento;
- Qualidade inferior em determinados cenários de tradução.

Com o objetivo de contornar essas limitações, novas abordagens foram propostas, incluindo o uso de mecanismos de atenção, melhorias na paralelização e, posteriormente, o desenvolvimento da arquitetura Transformer.(VASWANI et al., 2017)

Dessa forma, o próximo capítulo tem como objetivo apresentar essas abordagens, bem como conceitos relacionados que contribuem para o entendimento da evolução dos modelos de tradução automática neural até os modelos mais recentes, que apresentam elevado desempenho na tarefa de tradução entre línguas.

3 Referencial teórico

3.1 Tradução automática neural - NMT

3.2 Tokenização

3.3 Embedding

3.4 Modelo Sequence-to-Sequence

3.5 Função softmax

3.6 Mecanismo de Atenção

3.7 Arquitetura Transformer

3.7.1 Visão Geral

3.7.2 Codificador

3.7.3 Decodificador

3.7.4 Feed-Forward

3.7.5 multi-head attention

3.7.6 positional encoding

3.7.7 paralelização

3.8 Modelos de Tradução Open Source

3.8.1 MarianMT

3.8.2 M2M

3.8.3 NLLB

3.9 Métricas de Avaliação

3.9.1 BLEU

3.9.2 BERTScore

3.9.3 chrF

3.10 Eficiência Computacional

Referências

- ANAND, S. et al. *Why Transformers Are Replacing RNNs in NLP?* 2025. Acesso em: 31 mar. 2026. Disponível em: <<https://medium.com/@albusdor11/why-transformers-are-replacing-rnns-in-nlp-1c1ef7ad4993>>. Citado na página 11.
- BULLA, O. *Exclusivo: 7 em cada 10 brasileiros compram em sites estrangeiros*. 2024. Acesso em: 31 mar. 2026. Disponível em: <<https://forbes.com.br/forbes-money/2024/08/exclusivo-7-em-cada-10-brasileiros-compram-em-sites-estrangeiros/>>. Citado na página 11.
- CHAROENPORN SAWAT, P.; SORNLER TLAMVANICH, V.; CHAROENPORN, T. Improving translation quality of rule-based machine translation. In: *COLING-02: machine translation in Asia*. [S.l.: s.n.], 2002. Citado na página 15.
- CLARO, F. D. O avanço tecnológico no mundo econômico. *Revista FAE, Vitrine da Conjuntura*, v. 2, n. 8, p. 1–4, 2009. Citado na página 11.
- DANG, K. *Language Model History — Before and After Transformer: The AI Revolution*. 2023. Acesso em: 31 mar. 2026. Disponível em: <<https://medium.com/@kirudang/language-model-history-before-and-after-transformer-the-ai-revolution-bedc7948a130>>. Citado na página 11.
- ELAFFENDI, M.; ALRAJHI, K. Beyond the transformer: a novel polynomial inherent attention (pia) model and its great impact on neural machine translation. *Computational Intelligence and Neuroscience*, Wiley Online Library, v. 2022, n. 1, p. 1912750, 2022. Citado na página 18.
- FEINER, L.; LESWING, K. *The race to the 'universal translator': Inside the AI battle between Apple, Google and Meta*. 2025. Acesso em: 31 mar. 2026. Disponível em: <<https://www.cnbc.com/2025/09/12/apple-google-meta-universal-translator.html>>. Citado na página 12.
- LaraTranslate. *Neural Machine Translation: Evolution and Impact*. 2025. Acessado em: 3 abr. 2026. Disponível em: <<https://blog.laratranslate.com/neural-machine-translation-evolution-and-impact/>>. Citado nas páginas 18 e 19.
- Lokalise Team. *Statistical Machine Translation: What is it and How it Works*. 2025. <<https://lokalise.com/blog/statistical-machine-translation/>>. Accessed: 2026-04-02. Citado nas páginas 16 e 17.
- LOPEZ, A. Statistical machine translation. *ACM Comput. Surv.*, Association for Computing Machinery, New York, NY, USA, v. 40, n. 3, ago. 2008. ISSN 0360-0300. Disponível em: <<https://doi.org/10.1145/1380584.1380586>>. Citado na página 11.
- OKPOR, M. D. Machine translation approaches: issues and challenges. *International Journal of Computer Science Issues (IJCSI)*, International Journal of Computer Science Issues (IJCSI), v. 11, n. 5, p. 159, 2014. Citado na página 15.
- OLIVEIRA, A. *Apenas 1% dos brasileiros é fluente em inglês, aponta estudo*. 2026. Acesso em: 31 mar. 2026. Disponível em: <<https://www.educamaisbrasil.com.br/educacao/noticias/apenas-1-dos-brasileiros-e-fluente-em-ingles-aponta-estudo>>. Citado na página 12.
- S, S. Statistical vs rule based machine translation; A case study on indian language perspective. *CoRR*, abs/1708.04559, 2017. Disponível em: <<http://arxiv.org/abs/1708.04559>>. Citado nas páginas 14 e 16.

SCHUSTER, M.; JOHNSON, M.; THORBY, T. *Zero-Shot Translation with Google's Multilingual Neural Machine Translation System*. 2016. Acessado em: 3 abr. 2026. Disponível em: <<https://research.google/blog/zero-shot-translation-with-googles-multilingual-neural-machine-translation-system/>>. Citado na página 19.

TORREGROSA, D. et al. Leveraging rule-based machine translation knowledge for under-resourced neural machine translation models. In: *Proceedings of machine translation summit XVII: translator, project and user tracks*. [S.l.: s.n.], 2019. p. 125–133. Citado na página 11.

VASWANI, A. et al. Attention is all you need. *CoRR*, abs/1706.03762, 2017. Disponível em: <<http://arxiv.org/abs/1706.03762>>. Citado na página 19.

WANG, H. et al. Progress in machine translation. *Engineering*, Elsevier, v. 18, p. 143–153, 2022. Citado na página 18.

WANG, X. et al. Neural machine translation advised by statistical machine translation. In: *Proceedings of the AAAI conference on artificial intelligence*. [S.l.: s.n.], 2017. v. 31, n. 1. Citado nas páginas 16, 17 e 19.

WIKIPEDIA. *Rule-based machine translation* — *Wikipedia, The Free Encyclopedia*. 2026. <<http://en.wikipedia.org/w/index.php?title=Rule-based%20machine%20translation&oldid=1286745997>>. [Online; accessed 02-April-2026]. Citado na página 15.