

**CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA DE MINAS GERAIS
CAMPUS TIMÓTEO**

Marcos Vinícius de Oliveira Silva

**COMPARAÇÃO ENTRE MODELOS DE TRADUÇÃO NEURAI
BASEADOS NA ARQUITETURA TRANSFORMER DE CÓDIGO
ABERTO**

Timóteo

2026

Marcos Vinícius de Oliveira Silva

**COMPARAÇÃO ENTRE MODELOS DE TRADUÇÃO NEURAI
BASEADOS NA ARQUITETURA TRANSFORMER DE CÓDIGO
ABERTO**

Monografia apresentada à Coordenação de Engenharia de Computação do Campus Timóteo do Centro Federal de Educação Tecnológica de Minas Gerais para obtenção do grau de Bacharel em Engenharia de Computação.

Orientador: Douglas Nunes de Oliveira

Timóteo

2026

À, Jonas Garcia de Oliveira, colega, amigo e avô

Agradecimentos

Agradeço aos pais no primeiro parágrafo?

E à namorada ou ao namorado no segundo?

Orientador no terceiro?

Esta página de agradecimentos vive dando problemas.

“Por pior que a vida pareça, sempre existe algo que você possa fazer e ser bem-sucedido”.
Stephen Hawking

Resumo

Um único parágrafo que sintetize todo o meu trabalho. Organização de informação usando classificação facetada é útil para melhorar a indexação de documentos e a construção de sistemas de recuperação de informação corporativa. Essa hipótese baseia-se na evidência de facetas comuns a documentos de diferentes empresas e na flexibilidade da organização facetada. Entretanto, a classificação e indexação automáticas de um grande volume de documentos representam importantes obstáculos e nossa principal motivação. A pesquisa é descritiva, aplicada e experimental e tenta responder sobre a existência de características comuns a documentos do domínio corporativo e a possibilidade de indexação facetada automática. Duas coleções são usadas para avaliação, uma pública e outra particular. Os termos usados por autores de documentos foram obtidos através de documentos e expressões de busca. Foi empreendida uma análise preliminar do domínio corporativo, pela qual foram descobertas 12 categorias comuns e facetas úteis para o contexto de cada coleção de avaliação. A distribuição de assuntos em categorias apresentou alta correlação positiva usando o coeficiente de correlação de Spearman. Dez expressões de busca de usuários foram avaliadas no contexto da coleção particular e validaram as 12 categorias comuns. A avaliação empírica da trilha *Enterprise* da *Text Retrieval Conference* foi executada e os métodos de indexação, classificação e recuperação automáticos de informação facetada melhoraram a eficiência da recuperação sem fazer uso de serviços externos, como Wikipedia e metabuscadores, e sem fazer uso de estruturas hipertextuais presentes nos documentos da amostra. A avaliação empírica utilizou-se principalmente das características espaciais, temporais, de documento e de pessoal. A técnica de análise facetada mostrou-se promissora para os métodos de análise e comparação de coleções corporativas sem que dados puros sejam expostos a terceiros. A tese aponta direções de pesquisa para o uso dos métodos em outras coleções, para aperfeiçoamentos da organização da informação facetada, e para novas aplicações dos métodos também em outros domínios.

Palavras-chave: análise de domínio, análise facetada, recuperação de informação, informação corporativa.

Abstract

We hypothesise that information organisation based on faceted classification is useful to improve enterprise information retrieval systems. The existence of similar facets in documents from different companies and the known adaptability of facet organisation strengthen this hypothesis. We refer this work to the automated classification and indexing on large amounts of text files. This work is descriptive, applied, and experimental. It aimed to expose the main characteristics of the enterprise information, proposing a tentative generalisation to the enterprise domain and presenting some facets we can use to organise it and to support better information retrieval. It applied facet analysis to two enterprise collections and evaluated the resulting faceted classification. Terms were selected from documents and queries. We found twelve common categories and the distribution of document subjects across the categories presents strong positive correlation by the Spearman's rank correlation. Then, we obtained ten user queries and we adopted them to validate the found categories. We also used the Enterprise track of Text Retrieval Conference and its previous results as a Cranfield-like evaluation. The automated prototype used spatial, temporal, document and social characteristics. Thus, our empirical evaluation improved the information retrieval with no external dependency like Wikipedia or metasearch engines. The facet analysis was useful for comparing the companies with no desire to expose their information. The method can guide and stimulate future work and other companies can become more willing to take part in a research study.

Keywords: domain analysis, facet analysis, information retrieval, enterprise information.

Lista de ilustrações

Figura 1 – Tradução Automática Baseada em Regras	15
Figura 2 – Tradução Automática Baseada em estatística	17
Figura 3 – Tradução automática neural	18
Figura 4 – Tokenização de uma frase em português	20
Figura 5 – Conversão de tokens em embeddings	21
Figura 6 – Conversão de pontuações em probabilidades	22
Figura 7 – Propriedade de normalização da função softmax	22
Figura 8 – Tradução sem a utilização de um mecanismo de atenção	24
Figura 9 – Tradução com a utilização de um mecanismo de atenção	24

Lista de tabelas

Lista de abreviaturas e siglas

RNN	Redes neurais recorrentes
CPU	Unidade central de processamento
RAM	Memória de acesso aleatório
BLEU	Substituto para avaliação bilíngue
SMT	Tradução Automática Estatística
RBMT	Tradução Automática Baseada em Regras
NMT	tradução automática neural

Sumário

1	INTRODUÇÃO	11
1.1	Justificativa	11
1.2	Problema	12
1.3	Objetivos	12
2	EVOLUÇÃO DA TRADUÇÃO AUTOMÁTICA	14
2.1	Tradução Automática Baseada em Regras	14
2.2	Tradução Automática Estatística	16
2.3	Tradução automática neural	17
3	REFERENCIAL TEÓRICO	20
3.1	Tradução automática neural - NMT	20
3.2	Tokenização	20
3.3	Embedding	21
3.4	Função softmax	21
3.5	Mecanismo de Atenção	23
3.6	Arquitetura Transformer	24
3.6.1	Visão Geral	24
3.6.2	Codificador	25
3.6.3	Decodificador	25
3.6.4	Feed-Forward	25
3.6.5	multi-head attention	25
3.6.6	positional encoding	25
3.6.7	paralelização	25
3.7	Modelos de Tradução Open Source	25
3.7.1	MarianMT	25
3.7.2	M2M	25
3.7.3	NLLB	25
3.8	Métricas de Avaliação	25
3.8.1	BLEU	25
3.8.2	BERTScore	25
3.8.3	chrF	25
3.9	Eficiência Computacional	25
	REFERÊNCIAS	26

1 Introdução

O mundo passou e continua passando por grandes mudanças tecnológicas nos últimos anos, o que possibilitou a presença da tecnologia em diversos setores econômicos (CLARO, 2009). Juntamente com essa presença tecnológica, as pessoas passaram a se tornar mais ativas no ambiente virtual, uma vez que a tecnologia faz parte do dia a dia. Em conjunto com essa presença digital, tornou-se notável o aumento do consumo de conteúdos em outros idiomas, bem como a realização de compras de produtos, sejam eles físicos ou digitais, também em línguas estrangeiras (BULLA, 2024).

Ferramentas de tradução são muito úteis para pessoas que não são capazes de compreender a língua que está sendo apresentada. Uma alternativa para contornar o problema da barreira linguística é a utilização de tradutores automáticos, capazes de identificar o conteúdo transmitido por meio do contexto e da forma de escrita, gerando uma tradução que se assemelhe ao máximo à língua de destino. Atualmente, existem diferentes ferramentas que realizam a tradução de uma língua de origem para uma língua de destino. Como exemplo, podem ser citadas as ferramentas Google Tradutor, DeepL, Smartling e Lokalise, todas com o mesmo objetivo: traduzir textos mantendo o contexto e o sentido da sentença original.

Até o ano de 2017, diferentes técnicas e algoritmos foram utilizados para a tradução entre línguas. Dentre as abordagens existentes, destacam-se inicialmente as técnicas baseadas em regras gramaticais (Rule-Based Machine Translation - RBMT), que representaram uma das primeiras fases das ferramentas de tradução (TORREGROSA et al., 2019). Posteriormente, surgiram os modelos baseados em métodos estatísticos (Statistical Machine Translation – SMT), que representaram um avanço significativo na tarefa de tradução, alcançando níveis mais satisfatórios e adaptativos em comparação às abordagens baseadas em regras gramaticais (LOPEZ, 2008).

Ainda antes de 2017, modelos baseados em redes neurais recorrentes (RNN) passaram a ser amplamente utilizados na tarefa de tradução, sendo bem aceitos por apresentarem resultados superiores em relação às abordagens anteriores (DANG, 2023). No entanto, em 2017, foi proposta a arquitetura Transformer, que trouxe modificações relevantes em relação aos modelos anteriores, como o uso do mecanismo de autoatenção. Esse mecanismo possibilitou avanços significativos na identificação de contexto e na análise de sequências mais longas, contribuindo para traduções mais precisas, tanto em termos de contexto quanto na captura de dependências em textos mais extensos (ANAND et al., 2025).

1.1 Justificativa

Atualmente, existem diversos modelos de tradução baseados na arquitetura Transformer e disponibilizados como código aberto. Empresas como Meta e Google, além de iniciativas como o MarianMT, que não possui fins lucrativos, estão em constante desenvolvimento e pes-

quisa na área de tradução entre línguas (FEINER; LESWING, 2025). Esse cenário evidencia que a área de tradução automática encontra-se em constante evolução, podendo trazer benefícios em escala global, especialmente para a população brasileira, na qual apenas uma parcela possui fluência na língua inglesa (OLIVEIRA, 2026). Dessa forma, avanços em modelos de tradução podem ser amplamente aproveitados por pessoas que desejam ou necessitam consumir, comprar ou até mesmo comercializar produtos e conteúdos em outros idiomas, especialmente em inglês.

Apesar da ampla disponibilidade de modelos de tradução baseados na arquitetura Transformer, sejam eles desenvolvidos por organizações com ou sem fins lucrativos, existem diferenças relevantes entre esses modelos. Tais diferenças podem estar relacionadas à forma como a arquitetura é implementada, bem como às bases de dados utilizadas durante o treinamento. Como consequência, essas variações podem impactar diretamente o comportamento dos modelos em diferentes cenários, influenciando aspectos como consumo de memória, uso de CPU e tempo de resposta, mesmo quando submetidos à mesma entrada.

Diante desse contexto, este trabalho propõe a comparação entre diferentes modelos de tradução automática, com o objetivo de analisar seus desempenhos e apresentar resultados que auxiliem na escolha do modelo mais adequado para diferentes cenários de uso, considerando a tradução entre uma língua de origem e uma língua de destino.

1.2 Problema

A seguinte questão constitui o problema desta pesquisa: Qual é o desempenho de diferentes modelos de tradução entre línguas e automática, baseados na arquitetura Transformer para a tarefa de tradução do inglês para o português, considerando métricas como consumo de memória RAM, uso de CPU, pontuação BLEU, BERTScore e chrF, em diferentes cenários de teste?

1.3 Objetivos

Para responder ao problema proposto, o objetivo geral deste trabalho é investigar e comparar o desempenho de modelos de tradução entre línguas e automática baseados na arquitetura Transformer na tarefa de tradução do inglês para o português, considerando métricas de qualidade (BLEU, BERTScore e chrF) e eficiência computacional (uso de memória RAM e CPU) em diferentes cenários experimentais.

Também, objetivam-se mais especificamente:

1. Revisão bibliográfica sobre o funcionamento de modelos de tradução automática neural baseados na arquitetura Transformer;
2. Selecionar e configurar os modelos de tradução automática neural de código aberto;
3. Selecionar base de dados pública para comparação entre os modelos de tradução automática neural;

4. Avaliar qualidade de tradução utilizando mettricas como BLEU, BERTScore e chrF;
5. Medir eficiência de recursos computacionais quando se utiliza modelos de tradução;
6. Avaliar os modelos de tradução diferentes cenários de teste;
7. Analisar correlação entre métricas de qualidade de tradução.

2 Evolução da Tradução Automática

A área de tradução automática tem passado por transformações significativas ao longo dos anos, seja pela evolução de modelos específicos por meio de técnicas de otimização, seja pela proposição de novas arquiteturas que estabeleceram novos estados da arte. Este capítulo tem como objetivo apresentar um panorama da evolução das técnicas e modelos de tradução automática, desde as abordagens iniciais até os métodos mais recentes, discutindo suas principais características, vantagens e limitações.


2.1 Tradução Automática Baseada em Regras

A tradução automática baseada em regras, do inglês Rule-Based Machine Translation (RBMT), consiste em sistemas que operam com base em um conjunto de regras linguísticas previamente definidas para a língua de destino. Esses sistemas utilizam regras gramaticais para realizar a tradução entre línguas, exigindo um esforço humano significativo na elaboração de todos os componentes necessários para a tradução de uma língua de origem para uma língua de destino.

Entre esses componentes, destacam-se analisadores morfológicos, etiquetadores de classes gramaticais, analisadores sintáticos, dicionários bilíngues, regras de transferência, geradores morfológicos e regras de reordenação, entre outros (S, 2017).

A Figura 1 ilustra o processo de tradução baseado em regras. Nela, uma frase em inglês é fornecida para o sistema, e baseado nas regras pre-definidas da língua portuguesa como língua de destino a tradução é gerada.

Figura 1 – Tradução Automática Baseada em Regras



Fonte: (CHAROENPORNSAWAT; SORNLERLAMVANICH; CHAROENPORN, 2002) adaptada para português

A tradução automática baseada em regras teve início na década de 1970, sendo considerada um marco na área de tradução automática e uma abordagem inicialmente promissora (WIKIPEDIA, 2026). No entanto, algumas características limitaram sua adoção em larga escala (OKPOR, 2014):

- Escassez de dicionários bilíngues de alta qualidade, sendo sua construção uma tarefa custosa;
- Necessidade de configuração manual de diversas informações linguísticas;
- Dificuldade em lidar com ambiguidade linguística e expressões idiomáticas, especialmente em sistemas de grande escala.

Devido a essas limitações, tornou-se necessária a criação de novas abordagens capazes de lidar melhor com ambiguidade, dependências contextuais entre palavras e reduzir a

necessidade de intervenção humana na construção das traduções. Nesse contexto, surgiu a tradução automática baseada em Estatística (Statistical Machine Translation – SMT), que será abordada na próxima seção.

2.2 Tradução Automática Estatística

A abordagem estatística de tradução baseia-se em modelos probabilísticos extraídos de bases textuais bilíngues alinhadas, nos quais cada palavra ou frase da língua de destino é associada a elementos da língua de origem segundo uma determinada probabilidade. Dessa forma, as palavras ou expressões com maior probabilidade, dentre as opções geradas pelo modelo, tendem a corresponder à tradução mais adequada (S, 2017).

Em termos práticos, um modelo de tradução estatística é treinado com grandes volumes de textos paralelos, contendo a língua de origem e sua tradução correspondente na língua de destino. A partir desses dados, o modelo aprende padrões de correspondência entre palavras e frases, sendo capaz de estimar a tradução mais provável com base nas ocorrências observadas durante o treinamento (Lokalise Team, 2025).


O processo de tradução estatística envolve dois módulos principais: o modelo de tradução e o modelo de linguagem (WANG et al., 2017).

O modelo de tradução tem como objetivo mapear como palavras ou frases em uma língua geralmente se correspondem em outra, realizando essa análise no nível de frases, e não apenas de palavras isoladas. Esse cuidado evita traduções que não respeitem o contexto, já que uma mesma palavra na língua de origem pode ter múltiplas traduções possíveis na língua de destino.

O modelo de linguagem, por sua vez, recebe os possíveis mapeamentos gerados pelo modelo de tradução e seleciona a frase que apresenta a maior probabilidade de ocorrência na língua de destino, considerando padrões aprendidos a partir dos textos da base de observação. Esse módulo é essencial para produzir traduções mais naturais, que se aproximem do resultado esperado de uma tradução humana.

A imagem abaixo exemplifica este processo de tradução baseado no modelo estatístico.

Figura 2 – Tradução Automática Baseada em estatística



Fonte: (Lokalise Team, 2025) adaptada para português

É notável que traduções baseadas em estatística superaram traduções baseadas em regras, em qualidade e contexto, porém, os seguintes pontos podem ser destacados sobre traduções estatísticas (WANG et al., 2017):

- Criação de base de dados complexa;
- Resultados inesperados. Fluência superficial pode ser enganosa;
- Tradução baseada em estatística não funciona bem entre línguas que possuem ordem de palavras diferentes;
- Os resultados obtidos tendem a ser mais favoráveis para línguas europeias.
- Dificuldade em lidar com dependências de longa distância em frases.

Para contornar os problemas listados acima, um novo modelo foi proposto, o qual foi a base para construção de modelos utilizados atualmente, conhecido como aprendizado profundo, em inglês, deep learning, que será abordado no próximo capítulo.

2.3 Tradução automática neural

A tradução automática neural, em sua essência, utiliza redes neurais artificiais (Artificial Neural Networks - ANN), cujo objetivo é simular, de forma simplificada, o funcionamento do cérebro humano. Em termos gerais, o sistema recebe uma entrada, neste caso, um texto na língua de origem, e por meio de módulos internos da rede neural, realiza a tradução para a língua de destino (LaraTranslate, 2025).

O processo de tradução é realizado por meio de dois componentes principais: o codificador (encoder) e o decodificador (decoder) (WANG et al., 2022).


O componente de codificação tem como objetivo mapear o texto de entrada em um vetor de valores reais de múltiplas dimensões. Esse vetor representa, de forma abstrata, informações relevantes necessárias para a realização da tradução. A partir dessa representação vetorial, o componente de decodificação utiliza essas informações para gerar o texto correspondente na língua de destino.

De forma geral, o processo de tradução automática neural pode ser descrito pelas seguintes etapas (LaraTranslate, 2025):

- Conversão das palavras em vetores numéricos;
- Processamento desses vetores por meio de uma rede neural com múltiplas camadas;
- Geração de uma distribuição de probabilidade para possíveis traduções;
- Seleção da tradução mais provável.

A Figura 3 ilustra o processo de tradução utilizando redes neurais artificiais, destacando os componentes de codificação e decodificação.

Figura 3 – Tradução automática neural



Fonte: (ELAFFENDI; ALRAJHI, 2022)

O uso da tradução automática neural (Neural Machine Translation – NMT) representou, por muitos anos, uma substituição às técnicas de tradução baseadas em métodos estatísticos. Com a utilização da NMT, tornou-se possível gerar traduções sem a necessidade de intervenção humana direta, baseando-se inteiramente em grandes bases de textos e suas respectivas traduções, abordagem conhecida como aprendizado fim a fim (end-to-end) (LaraTranslate, 2025).

Essa abordagem possibilitou a geração de traduções com maior captura de contexto e maior naturalidade quando comparadas às traduções estatísticas e baseadas em regras, além

de melhorar a modelagem das relações entre palavras em uma sentença, um dos principais desafios enfrentados pelas abordagens anteriores (WANG et al., 2017).

Um marco importante na adoção da tradução automática neural foi a substituição dos modelos estatísticos pelo uso de NMT no Google Tradutor, realizada pela empresa Google em 2016 (SCHUSTER; JOHNSON; THORBY, 2016), evidenciando uma mudança significativa na forma como sistemas de tradução eram desenvolvidos até então.

Apesar dos avanços proporcionados pela tradução automática neural em relação aos métodos anteriores, ainda existem limitações associadas aos modelos baseados em componentes de codificação e decodificação. Dentre essas limitações, destacam-se (LaraTranslate, 2025):

- Dificuldade na paralelização do processamento de sequências de entrada;
- Limitações no tratamento de dependências de longo alcance entre palavras;
- Maior complexidade no processo de treinamento;
- Qualidade inferior em determinados cenários de tradução.

Com o objetivo de contornar essas limitações, novas abordagens foram propostas, incluindo o uso de mecanismos de atenção, melhorias na paralelização e, posteriormente, o desenvolvimento da arquitetura Transformer.(VASWANI et al., 2017)

Dessa forma, o próximo capítulo tem como objetivo apresentar essas abordagens, bem como conceitos relacionados que contribuem para o entendimento da evolução dos modelos de tradução automática neural até os modelos mais recentes, que apresentam elevado desempenho na tarefa de tradução entre línguas.

3 Referencial teórico

3.1 Tradução automática neural - NMT

Como apresentado na Seção 2.3, a tradução automática neural é uma importante tarefa que tem como objetivo realizar a tradução de uma língua de origem para uma língua de destino por meio de sistemas computacionais, mais especificamente utilizando redes neurais artificiais. Essas redes buscam simular, de forma simplificada, o funcionamento do cérebro humano, permitindo a geração de traduções que se aproximem, o máximo possível, de traduções realizadas por humanos (TAN et al., 2020).

As seções seguintes têm como objetivo apresentar os conceitos teóricos que fundamentam o estudo da arquitetura Transformer, proposta com o intuito de aprimorar a tarefa de tradução automática. Essa arquitetura introduz novos componentes e combina técnicas já existentes de forma mais eficiente. Como resultado, a arquitetura Transformer estabeleceu um novo estado da arte na tradução automática baseada em redes neurais artificiais (VASWANI et al., 2017).

3.2 Tokenização

Tokenização, ou *tokenization* em inglês, é uma etapa de pré-processamento fundamental no processamento de linguagem natural. Esse processo consiste em converter textos em unidades menores, como bytes, caracteres, subpalavras, palavras ou expressões de múltiplas palavras, denominadas *tokens*.

A Figura abaixo ilustra esse processo, no qual um texto é segmentado em tokens e, posteriormente, cada token é representado por um número, comumente chamado de identificador ou id, cujo objetivo é mapear um token de volta à uma palavra ao final de uma tradução entre línguas (ASGARI; KHEIR; JAVAHERI, 2025).




Figura 4 – Tokenização de uma frase em português

Fonte: Criada pelo autor baseado na ferramenta openai tokenizer

3.3 Embedding

O processamento de linguagem natural, em conjunto com tarefas de tradução entre línguas, exige que palavras ou tokens sejam representados de forma numérica. Nesse contexto, *embeddings* correspondem ao processo de representação de palavras ou tokens em um espaço vetorial de múltiplas dimensões, no qual relações semânticas podem ser modeladas por meio de relações matemáticas.

A representação de tokens em vetores de múltiplas dimensões é fundamental, pois esses vetores são capazes de capturar informações semânticas relevantes. Dessa forma, palavras com significados semelhantes tendem a possuir representações vetoriais próximas nesse espaço. Por exemplo, os vetores associados às palavras “gato” e “cachorro” tendem a ser mais próximos entre si do que em relação à palavra “morango”.

Essa propriedade é essencial para a geração de traduções mais naturais e coerentes, uma vez que permite aos modelos capturar relações semânticas entre palavras e contextos linguísticos (HESSANI, 2025).

A Figura abaixo ilustra o processo de conversão de uma sequência de tokens em representações vetoriais em um espaço de multiplas dimensões.

id do token	token	Vetor de Embedding (1536 dimensões)
47753	Uma	[-0.027466, 0.002899, -0.005188 ... 0.021606]
6257	raposa	[-0.018555, 0.000912, 0.010986 ... -0.015991]
6935	pula	[-0.026978, -0.012939, 0.021362 ... 0.042725]
79334	sobre	[-0.012085, 0.001244, -0.069336 ... -0.001213]
4844	o	[-0.001785, -0.008789, 0.006195 ... -0.016235]
293	cachorro	[0.016357, -0.039062, 0.045898 ... 0.001686]
168983	preguiçoso	[-0.000721, -0.021118, 0.027710 ... -0.051270]
13	.	[-0.047852, 0.057861, -0.069336 ... 0.005280]

Figura 5 – Conversão de tokens em embeddings

Fonte: (HESSANI, 2025) adaptada pelo autor

3.4 Função softmax

Softmax é uma função matemática frequentemente utilizada como função de ligação probabilística para dados categóricos não ordenados. Dado um vetor de entradas, a aplicação da função softmax resulta em uma saída composta por uma distribuição de probabilidades, na qual cada valor está associado a um elemento da entrada.

A função softmax é amplamente utilizada em modelos de aprendizado de máquina, especialmente em tarefas que envolvem classificação e tradução automática, sendo respon-

sável por converter pontuações geradas pelo modelo em distribuições de probabilidade sobre os possíveis resultados de saída.

A função softmax é definida matematicamente como:

$$p_i = \frac{\exp(\alpha s_i)}{\sum_j \exp(\alpha s_j)}$$

onde:

- α : parâmetro de escala da função softmax, frequentemente omitido e considerado igual a 1;
- s_i : valor da i-ésima posição do vetor de pontuações.

A Figura 6 ilustra o funcionamento da função softmax aplicada a um vetor de pontuações, resultando na geração de uma distribuição de probabilidades associada a cada elemento de entrada.




Figura 6 – Conversão de pontuações em probabilidades

Fonte: (FRANKE; DEGEN, 2023) adaptada pelo autor

Uma das propriedades mais importantes da função softmax em modelos neurais é a sua capacidade de normalização, garantindo que a soma das probabilidades geradas seja igual a 1. Essa característica permite interpretar a saída do modelo como uma distribuição de probabilidade válida sobre os possíveis resultados. A Figura 7 ilustra essa propriedade (FRANKE; DEGEN, 2023).




Figura 7 – Propriedade de normalização da função softmax

Fonte: (FRANKE; DEGEN, 2023)

3.5 Mecanismo de Atenção

O mecanismo de atenção é uma técnica cujo objetivo é identificar e relacionar as partes mais relevantes dos dados de entrada durante o processamento de sequências.

Grande parte das arquiteturas de tradução automática baseadas em redes neurais utiliza dois componentes principais: o codificador (encoder) e o decodificador (decoder), conforme apresentado na Seção 2.3. No entanto, modelos tradicionais baseados apenas nessa estrutura enfrentam limitações ao representar sequências longas, uma vez que toda a informação precisa ser comprimida em um vetor de dimensão fixa.

Nesse contexto, os mecanismos de atenção modificam a forma como redes neurais processam dados sequenciais, permitindo acesso direto a todas as posições da sequência de entrada. Isso elimina a necessidade de compressão em uma única representação vetorial e possibilita uma melhor captura de relações contextuais.

A operação de atenção consiste na computação de uma soma ponderada sobre os dados de entrada, na qual cada peso representa a importância de uma determinada posição da sequência para o elemento que está sendo processado. Na prática, isso permite que diferentes partes da entrada se relacionem entre si, possibilitando a captura de dependências contextuais entre palavras em tarefas de tradução.

As equações a seguir definem a formulação matemática de um mecanismo de atenção (HAYS, 2026):

$$e_{ij} = \text{score}(\mathbf{q}_i, \mathbf{k}_j)$$

$$\alpha_{ij} = \text{softmax}(e_{ij})$$

$$\mathbf{c}_i = \sum_{j=1}^n \alpha_{ij} \mathbf{v}_j$$

Onde:

- $\mathbf{q}_i$: vetor de consulta (*query*), representando a informação buscada na posição i ;
- $\mathbf{k}_j$: vetor de chave (*key*), representando a informação disponível na posição j ;
- $\mathbf{v}_j$: vetor de valor (*value*), contendo a informação a ser agregada;
- α_{ij} : peso de atenção, formando uma distribuição de probabilidade sobre as posições de entrada, indicando o grau de contribuição de cada posição para a saída na posição i .

A Figura 8 ilustra um exemplo de tradução automática sem o uso de mecanismos de atenção, no qual é possível observar limitações na captura de relações entre palavras da língua de origem e da língua de destino.




Figura 8 – Tradução sem a utilização de um mecanismo de atenção

Fonte: (RASCHKA, 2023)

Por outro lado, a Figura 9 apresenta o uso do mecanismo de atenção, evidenciando a capacidade do modelo de capturar relações entre palavras, resultando em traduções mais coerentes e contextualizadas.




Figura 9 – Tradução com a utilização de um mecanismo de atenção

Fonte: (RASCHKA, 2023)

3.6 Arquitetura Transformer

3.6.1 Visão Geral

A arquitetura Transformer foi proposta em 2017 pela empresa Google no artigo intitulado “*Attention Is All You Need*”, representando uma mudança de paradigma em relação aos modelos até então predominantes, baseados em redes neurais recorrentes (RNN).

Essa arquitetura introduziu avanços importantes, como a capacidade de capturar dependências de longo alcance entre elementos de uma sequência e o processamento paralelo dos dados, resultando em um novo estado da arte em diversas tarefas de processamento de linguagem natural.

A partir da arquitetura Transformer, tornou-se possível o desenvolvimento de modelos avançados de geração de texto, como o GPT, da OpenAI, o Gemini, da Google, e o LLaMA, da Meta, além de impulsionar a evolução de modelos de tradução automática, como o MarianMT, de código aberto, e os modelos M2M e NLLB, também desenvolvidos pela Meta. Esses modelos representam avanços significativos na tarefa de tradução entre línguas, todos baseados nos princípios introduzidos pela arquitetura Transformer (C4LAB, 2023).

3.6.2 Codificador

3.6.3 Decodificador

3.6.4 Feed-Forward

3.6.5 multi-head attention

3.6.6 positional encoding

3.6.7 paralelização

3.7 Modelos de Tradução Open Source

3.7.1 MarianMT

3.7.2 M2M

3.7.3 NLLB

3.8 Métricas de Avaliação

3.8.1 BLEU

3.8.2 BERTScore

3.8.3 chrF

3.9 Eficiência Computacional

Referências

- ANAND, S. et al. *Why Transformers Are Replacing RNNs in NLP?* 2025. Acesso em: 31 mar. 2026. Disponível em: <<https://medium.com/@albusdor11/why-transformers-are-replacing-rnns-in-nlp-1c1ef7ad4993>>. Citado na página 11.
- ASGARI, E.; KHEIR, Y. E.; JAVAHERI, M. A. S. *MorphBPE: A Morpho-Aware Tokenizer Bridging Linguistic Complexity for Efficient LLM Training Across Morphologies*. 2025. Disponível em: <<https://arxiv.org/abs/2502.00894>>. Citado na página 20.
- BULLA, O. *Exclusivo: 7 em cada 10 brasileiros compram em sites estrangeiros*. 2024. Acesso em: 31 mar. 2026. Disponível em: <<https://forbes.com.br/forbes-money/2024/08/exclusivo-7-em-cada-10-brasileiros-compram-em-sites-estrangeiros/>>. Citado na página 11.
- C4LAB. *Arquitetura Transformer: Explicação*. 2023. Acessado em: 12 de abril de 2026. Disponível em: <<https://c4lab.com.br/arquitetura-transformer-explicacao/>>. Citado na página 24.
- CHAROENPORN SAWAT, P.; SORNLER TLAMVANICH, V.; CHAROENPORN, T. Improving translation quality of rule-based machine translation. In: *COLING-02: machine translation in Asia*. [S.l.: s.n.], 2002. Citado na página 15.
- CLARO, F. D. O avanço tecnológico no mundo econômico. *Revista FAE, Vitrine da Conjuntura*, v. 2, n. 8, p. 1–4, 2009. Citado na página 11.
- DANG, K. *Language Model History — Before and After Transformer: The AI Revolution*. 2023. Acesso em: 31 mar. 2026. Disponível em: <<https://medium.com/@kirudang/language-model-history-before-and-after-transformer-the-ai-revolution-bedc7948a130>>. Citado na página 11.
- ELAFFENDI, M.; ALRAJHI, K. Beyond the transformer: a novel polynomial inherent attention (pia) model and its great impact on neural machine translation. *Computational Intelligence and Neuroscience*, Wiley Online Library, v. 2022, n. 1, p. 1912750, 2022. Citado na página 18.
- FEINER, L.; LESWING, K. *The race to the 'universal translator': Inside the AI battle between Apple, Google and Meta*. 2025. Acesso em: 31 mar. 2026. Disponível em: <<https://www.cnbc.com/2025/09/12/apple-google-meta-universal-translator.html>>. Citado na página 12.
- FRANKE, M.; DEGEN, J. The softmax function: Properties, motivation, and interpretation. *PsyArXiv DOI*, v. 10, 2023. Citado na página 22.
- HAYS, H. *Attention mechanisms in neural networks*. 2026. Disponível em: <<https://arxiv.org/abs/2601.03329>>. Citado na página 23.
- HESSANI, H. S. *LLM Embeddings Explained: A Visual and Intuitive Guide*. 2025. Citado na página 21.
- LaraTranslate. *Neural Machine Translation: Evolution and Impact*. 2025. Acessado em: 3 abr. 2026. Disponível em: <<https://blog.laratranslate.com/neural-machine-translation-evolution-and-impact/>>. Citado nas páginas 17, 18 e 19.

- Lokalise Team. *Statistical Machine Translation: What is it and How it Works*. 2025. <<https://lokalise.com/blog/statistical-machine-translation/>>. Accessed: 2026-04-02. Citado nas páginas 16 e 17.
- LOPEZ, A. Statistical machine translation. *ACM Comput. Surv.*, Association for Computing Machinery, New York, NY, USA, v. 40, n. 3, ago. 2008. ISSN 0360-0300. Disponível em: <<https://doi.org/10.1145/1380584.1380586>>. Citado na página 11.
- OKPOR, M. D. Machine translation approaches: issues and challenges. *International Journal of Computer Science Issues (IJCSI)*, International Journal of Computer Science Issues (IJCSI), v. 11, n. 5, p. 159, 2014. Citado na página 15.
- OLIVEIRA, A. *Apenas 1% dos brasileiros é fluente em inglês, aponta estudo*. 2026. Acesso em: 31 mar. 2026. Disponível em: <<https://www.educamaisbrasil.com.br/educacao/noticias/apenas-1-dos-brasileiros-e-fluente-em-ingles-aponta-estudo>>. Citado na página 12.
- RASCHKA, S. *Understanding and Coding Self-Attention and Multi-Head Attention from Scratch*. 2023. Acessado em: 12 de abril de 2026. Disponível em: <<https://sebastianraschka.com/blog/2023/self-attention-from-scratch.html>>. Citado na página 24.
- S, S. Statistical vs rule based machine translation; A case study on indian language perspective. *CoRR*, abs/1708.04559, 2017. Disponível em: <<http://arxiv.org/abs/1708.04559>>. Citado nas páginas 14 e 16.
- SCHUSTER, M.; JOHNSON, M.; THORBY, T. *Zero-Shot Translation with Google's Multilingual Neural Machine Translation System*. 2016. Acessado em: 3 abr. 2026. Disponível em: <<https://research.google/blog/zero-shot-translation-with-googles-multilingual-neural-machine-translation-system/>>. Citado na página 19.
- TAN, Z. et al. Neural machine translation: A review of methods, resources, and tools. *AI Open*, Elsevier, v. 1, p. 5–21, 2020. Citado na página 20.
- TORREGROSA, D. et al. Leveraging rule-based machine translation knowledge for under-resourced neural machine translation models. In: *Proceedings of machine translation summit XVII: translator, project and user tracks*. [S.l.: s.n.], 2019. p. 125–133. Citado na página 11.
- VASWANI, A. et al. Attention is all you need. *CoRR*, abs/1706.03762, 2017. Disponível em: <<http://arxiv.org/abs/1706.03762>>. Citado nas páginas 19 e 20.
- WANG, H. et al. Progress in machine translation. *Engineering*, Elsevier, v. 18, p. 143–153, 2022. Citado na página 18.
- WANG, X. et al. Neural machine translation advised by statistical machine translation. In: *Proceedings of the AAAI conference on artificial intelligence*. [S.l.: s.n.], 2017. v. 31, n. 1. Citado nas páginas 16, 17 e 19.
- WIKIPEDIA. *Rule-based machine translation* — *Wikipedia, The Free Encyclopedia*. 2026. <<http://en.wikipedia.org/w/index.php?title=Rule-based%20machine%20translation&oldid=1286745997>>. [Online; accessed 02-April-2026]. Citado na página 15.